

Связь дисперсий последовательных слоев глубины нейросети

Эдучеатед guess: зависит от (начальной инициализации) весов

Рассмотрим кейс:

$$w_i \sim \mathcal{U}\left[-\frac{1}{\sqrt{n_{out}}}, \frac{1}{\sqrt{n_{out}}}\right], \text{ где}$$

$w_i \in W_{ij}$ - матрица весов

n_{out} - кол-во нейронов на выходном слое

$$\mathbb{E}[w_i] = 0, \quad \text{Var}[w_i] = \frac{1}{3n_{out}}$$

~~Анализ~~

Из лекции мы помним, что

$$\text{Var}(y_i^{(l+1)}) = \text{Var}(w_i^{(l+1)}) \text{Var}(y_i^{(l)})$$

$$\text{и.е.} = \text{Var}(w_i^{(l+1)}) \text{Var}(w_i^{(l)}) \text{Var}(y_i^{(l-1)})$$

= ...

$$= \prod_l \text{Var}(w_i^{(l)}) \text{Var}(y_i^{(0)})$$

$$= \prod_l \frac{1}{3n_{out}^{(l)}} \cdot \text{Var}(y_i^{(0)}) \xrightarrow{l \text{ большая}} 0$$

на каждом слое веса распределены одинаково и не зависят др. от др.

где l - номер слоя

Для То есть с увеличением глубины сети сигнал затухает: нулевое математическое ожидание и дисперсия.

Это уже достаточно плохо, но дальше только хуже. Рассмотрим обратный проход!

Посчитаем градиент функции ошибки L на слое l . Вспомогательным, что слой $l+1$ - это

$$y_i^{(l+1)} = f\left(\sum_j w_{ij}^{(l+1)} y_j^{(l)}\right) \quad y_i^{(l+1)} = f\left(\sum_j w_{ij}^{(l+1)} y_j^{(l)}\right)$$

↑
ф-ция активации $w_{ij}^{(l+1)}$ - веса

$$\frac{\partial L}{\partial y_i^{(l)}} = \sum_j \frac{\partial L}{\partial y_j^{(l+1)}} \cdot \frac{\partial y_j^{(l+1)}}{\partial y_i^{(l)}} = \sum_j \frac{\partial L}{\partial y_j^{(l+1)}} \left(\frac{\partial f}{\partial y_i^{(l)}} \right) \frac{\partial (\sum_j w_{ij}^{(l+1)} y_j^{(l)})}{\partial y_i^{(l)}} =$$

↑
не зависит от j

$$= \frac{\partial f}{\partial y_i^{(l)}} \sum_j \frac{\partial L}{\partial y_j^{(l+1)}} \cdot w_{ij}^{(l+1)}$$

Для симметричной относительно нуля координат ф-ции активации f (напр., \tanh)

$\frac{\partial f}{\partial y_i^{(l)}} \approx 1$ в окрестности нуля
(рассматриваем именно эту область, потому что у нас нулевое математическое ожидание)

$$\text{Var}\left(\frac{\partial L}{\partial y_i^{(l)}}\right) = \text{Var}\left(\sum_j \frac{\partial L}{\partial y_j^{(l+1)}} w_{ij}^{(l+1)}\right) = \sum_j \text{Var}\left(\frac{\partial L}{\partial y_j^{(l+1)}}\right) \cdot \text{Var} w_{ij}^{(l+1)}$$

$$\approx \frac{1}{3n_{in}} \sum_j \text{Var} \frac{\partial L}{\partial y_j^{(l+1)}}$$

число входящих нейронов

И здесь дисперсия стремится к нулю.

Вывод: такие инициализации весов $w_i \sim \mathcal{U}\left[-\frac{1}{\sqrt{n_{out}}}, \frac{1}{\sqrt{n_{out}}}\right]$ не подходит для глубоких сетей.

Решение

- Xavier initialization для симметричной ф-ции активации
- He initialization для ReLU.